


**МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ
РОССИЙСКОЙ ФЕДЕРАЦИИ**
Федеральное государственное бюджетное образовательное учреждение
высшего образования
**«Сибирский государственный университет науки и технологий
имени академика М.Ф. Решетнева»**
Институт информатики и телекоммуникаций
институт/факультет/подразделение
Системного анализа и исследования операций
кафедра/цикловая комиссия

КУРСОВАЯ РАБОТА

по дисциплине «введение в анализ данных и теорию систем»
тема «исследования эффективности линейной модели в задаче прогнозирования
стоимости недвижимости»

Преподаватель


подпись, дата

В.Л. Липинский

инициалы, фамилия

Обучающийся

БИД25-01 25150610
номер группы, зачетной книжки

подпись, дата

А. И. Доронин

инициалы, фамилия

СОДЕРЖАНИЕ

ВВЕДЕНИЕ	3
1 ПОСТАНОВКА ЗАДАЧИ	4
2 ВИЗУАЛЬНЫЙ АНАЛИЗ ДАННЫХ	5
3 МОДЕЛИРОВАНИЕ	12
ЗАКЛЮЧЕНИЕ	16
СПИСОК ИСПОЛЬЗУЕМОЙ ЛИТЕРАТУРЫ.....	18
ПРИЛОЖЕНИЕ	20

ВВЕДЕНИЕ

В современном мире рынок недвижимости является одной из ключевых сфер экономики. Точная оценка стоимости жилья необходима как покупателям и продавцам, так и инвесторам, банкам и государственным учреждениям. Особую значимость эта задача приобретает в крупных городах, где цена квадратного метра зависит от множества факторов: транспортной доступности, возраста здания, наличия инфраструктуры и других характеристик. Использование методов машинного обучения, в частности регрессионного анализа, позволяет выявлять скрытые закономерности и строить объективные прогнозы, что делает процесс оценки более прозрачным и обоснованным. Линейная регрессия выбрана благодаря своей интерпретируемости и простоте реализации [2, 5, 9].

Целью данной курсовой работы является повышение точности прогнозирования стоимости недвижимости за счет построения и анализа модели линейной регрессии на основе набора данных *Real Estate Valuation Data Set* [1].

Для достижения цели планируется решение следующих задач:

1. Загрузка и обзор данных
2. Визуальный анализ данных
3. Обработка данных
4. Моделирование
5. Оценка качества модели

Курсовая работа состоит из следующих разделов: введение, постановка задачи, визуальный анализ данных, моделирование, оценка качества модели, заключение, список использованной литературы и приложение. Теоретической основой работы послужили источники [2, 3, 5, 6, 9], в которых рассмотрены методы линейной регрессии, метод наименьших квадратов и метрики качества.

1 ПОСТАНОВКА ЗАДАЧИ

В рамках данной курсовой работы используется датасет Real estate valuation data set, размещенный в открытом доступе на репозитории UCI Machine Learning Repository [1]. Данные содержат информацию о реальных сделках с недвижимостью, совершенных в районе Синьдянь (Новый Тайбэй, Тайвань) в период с 2012 по 2013 год. Датасет включает 6 признаков (дата, возраст дома, расстояние до метро, число магазинов, широта, долгота) и целевую переменную - цену за единицу площади. Пропуски отсутствуют.

Тип решаемой задачи – регрессия, то есть прогнозирование непрерывной числовой величины. Необходимо по характеристикам объекта недвижимости предсказать его стоимость.

Математически задача формулируется следующим образом. Для каждого i -го наблюдения известен вектор признаков $x_i = (x_1, \dots, x_6)$ и цена y_i . Требуется найти коэффициенты $b_0, \dots, b_6$ линейной модели:

$$y = b_0 + b_1x_1 + \dots + b_6x_6$$

Для нахождения коэффициентов используется метод наименьших квадратов (МНК). В матричной форме решение имеет вид:

$b = (X^T X)^{-1} X^T y$, где X – матрица признаков, дополненная столбцом единиц.

Для оценки качества модели воспользуемся метриками MAE (средняя абсолютная ошибка), RMSE (среднеквадратическая ошибка), R^2 (коэффициент детерминации) [3].

Решение реализуется на языке программирования Python с дополнительными библиотеками pandas [7, 12], numpy [8, 11], plotly [4,10].

2 ВИЗУАЛЬНЫЙ АНАЛИЗ ДАННЫХ

Целью визуального анализа данных является предварительное изучение структуры данных, выявление взаимосвязей между признаками и целевой переменной, обнаружение выбросов и оценка пригодности признаков для построения линейной регрессионной модели. Визуализация данных выполнена с использованием библиотеки Plotly [4, 10].

Датасет содержит 414 наблюдений и 7 столбцов (6 признаков и 1 целевая переменная). Пропуски отсутствуют. Целевая переменная – Y house price of unit area (цена за единицу площади).

Признаки:

- X1 transaction date - дата сделки (в долях года);
- X2 house age – возраст дома (в годах);
- X3 distance to the nearest MRT station – расстояние до ближайшей станции метро (в метрах);
- X4 number of convenience stores – количество магазинов в шаговой доступности;
- X5 latitude – широта;
- X6 longitude – долгота;

Для оценки диапазона и наличия выбросов была построена диаграмм размаха (boxplot) цены недвижимости (см. рисунок 1):



Рисунок 1 - Boxplot для признака y

На рисунке 1 видно, что основана масса наблюдений сосредоточена в диапазоне от 20 до 50 единиц цены. Однако присутствуют аномальные значения: минимальное значение 7.6 и максимальное 117.5. Эти точки значительно выбиваются из общего распределения и могут негативно влиять на качество модели линейной регрессии, так как метод наименьших квадратов чувствителен к выбросам. Влияние выбросов на модель линейной регрессии рассмотрено в [3, 5].

Для устранения выбросов был применен процентильный метод: удалены наблюдения, попадающие в нижний 1% и верхний 1% распределения целевой переменной. Процентильный метод удаления выбросов описан в литературе [3] как простой и эффективный способ очистки данных. Также были удалены объекты до метро более 6000 метров, так как значения не характерны для городской застройки и создают неоправданно большой размах признака.

После очистки данных из 414 наблюдений осталось 404 (удалено 10 строк, около 2,4% данных). Диапазон цен сократился. Распределение стало более компактным и симметричным (см. рисунок 2). Дальнейший визуальный анализ проводится на очищенной выборке.




Рисунок 2 - Boxplot y после очистки

Для каждого признака была построена диаграмма рассеивания с целевой переменной. Цель – выявить характер зависимости (линейная, нелинейная или отсутствие связи) и принять решение о включении признака в модель.

Признак X1 (дата сделки)

Рисунок 3 - Зависимость цены от даты сделки




Рисунок 3 - график рассеивания с X1

На рисунке 3 представлен график зависимости цены от даты сделки. Все

наблюдения расположены в узком диапазоне от 2012.6 до 2013.6 (примерно 11 месяцев). Цены не демонстрирует значимой динамики за этот период, разброс значений одинаков на всем промежутке. Признак не несет полезной информации для прогнозирования и исключается из модели.

Признак X2 (возраст дома)

Рисунок 4 - Зависимость цены от возраста дома




Рисунок 4 - график рассеивания с X2

На рисунке 4 видно, что явная линейная связь между возрастом дома и ценой отсутствует. Точки разбросаны по всему диапазону цен: встречаются как новые дома (возраст 0-5 лет) с низкой ценой, так и старые (более 40 лет) с высокой ценой, но при совместном использовании с признаками X3 и X4 (см. разделе 3) возраст дома дает значительный прирост качества модели. Поэтому возраст дома включается в финальную модель.

Признак X3 (расстояние до метро)

Рисунок 5 - Зависимость цены от расстояния до метро




Рисунок 5 - график рассеивания с X3

На рисунке 5 отчетливо наблюдается отрицательная связь: чем дальше объект находится от станции метро, тем ниже цена. При расстоянии до 500 метров цены достигают 60-70 единиц, тогда как при расстоянии более 300 метров цены не превышают 30 единиц. Зависимость близка линейной, признак включается модель.

Признак X4 (количество магазинов)

Рисунок 6 - Зависимость цены от количества магазинов




Рисунок 6 - график рассеивания с X4

На рисунке 6 видна положительная связь. Объекты с нулевым или одним магазином в округе имеют преимущественно низкие цена (10-40 единиц). При

увеличении количества магазинов до 7-10 цены достигают 50-70 единиц. Зависимость прослеживается, признак включается в модель.

Признак X5 (широта)

Рисунок 7 - Зависимость цены от широты




Рисунок 7 - график рассеивания с X5

На рисунке 7 показана зависимость цены от широты. Явной линейной связи не наблюдается: при разных значениях широты встречаются как низкие, так и высокие цены. Признак не подходит для линейной регрессии и исключается.

Признак X6 (долгота)

Рисунок 8 - Зависимость цены от долготы




Рисунок 8 - график рассеивания с X6

Аналогично широте, на рисунке 8 долгота не демонстрирует линейной зависимости от цены. Географические координаты в чистом виде плохо интерпретируются в линейной модели, тем более что расстояние до метро уже учитывает локацию. Признак исключается.

В результате визуального анализа:

- Обнаружены и удалены выбросы (процентильный метод, отсечение 1% снизу и сверху)
- Для дальнейшего моделирования отобраны три признака: X2 (возраст дома), X3 (расстояние до метро) и X4 (количество магазинов)
- Признаки X1, X5, X6 исключены из модели ввиду отсутствия линейной связи с целевой переменной.

Таким образом, подготовлена выборка, пригодная для построения модели линейной регрессии. Анализ признаков и отбор наиболее информационных проведён на основе рекомендаций из [2, 5].

3 МОДЕЛИРОВАНИЕ

После визуального анализа для построения модели отобраны два признака:

- X_2 – возраст дома (в годах)
- X_3 – расстояние до ближайшей станции метро (в метрах)
- X_4 – количество магазинов в шаговой доступности

Целевая переменная – Y (цена за единицу площади).

Всего в очищенной выборке содержится 404 наблюдений. Для корректной оценки качества модели данные были разделены на обучающую и тестовую выборки в соотношении 80% на 20% с использованием случайного разбиения. Обучающая выборка используется для подбора коэффициентов модели, тестовая – для проверки качества на данных, не участвовавших в обучении. Такое разделение является стандартной практикой [9, с. 120].

Для прогнозирования цены используется модель множественно линейной регрессии:

$$\hat{y} = b_0 + b_1x_2 + b_2x_3 + b_3x_4$$

где:

- $\hat{y}$ – предсказанная цена за единицу площади;
- x_2 – возраст дома;
- x_3 – расстояние до метро;
- x_4 – количество магазинов;
- b_0 – свободный член;
- b_1, b_2, b_3 - коэффициенты при признаках

Коэффициенты находятся методом наименьших квадратов (МНК), который минимизирует сумму квадратов отклонений предсказанных значений от фактических [5, 6]:

$$S = \sum (y_i - \hat{y}_i) \rightarrow \min$$

В матричной форме решение имеет вид:

$$b = (X^T X)^{-1} X^T y$$

где X – матрица признаков, дополненная столбцом единиц для учёта свободного члена b_0 .

Модель реализована на языке python с использованием библиотек NumPy [8, 11] и Pandas [7, 12]. Линейная регрессия реализована вручную с помощью формулы нормального уравнения.

Код:

```
# Модель с X2, X3, X4
x_raw = df[["X2 house age", "X3 distance to the nearest MRT station",
"X4 number of convenience stores"]].values
y = df["Y house price of unit area"].values

X = np.hstack([np.ones((x_raw.shape[0], 1)), x_raw])

np.random.seed(42)

indices = np.arange(len(X))
np.random.shuffle(indices)

split_idx = int(0.8*len(X))

train_indices = indices[:split_idx]
test_indices = indices[split_idx:]

X_train = X[train_indices]
X_test = X[test_indices]
y_train = y[train_indices]
y_test = y[test_indices]

coef = np.linalg.inv(X_train.T @ X_train) @ X_train.T @ y_train

b0, b1, b2, b3 = coef

y_pred = X_test @ coef
```

Результат вычислений:

- $b_0 = 41.03$
- $b_1 = -0.21$
- $b_2 = -0.005$
- $b_3 = 1.42$

Таким образом, модель имеет вид:

$$\hat{y} = 41.03 - 0.21x_2 - 0.005x_3 + 1.42x_4$$

Интерпретация коэффициентов [2, 5]:

- Свободный член $b_0 = 41.03$ показывает предсказанную цену при нулевом расстоянии до метро и отсутствии магазинов.
- Коэффициент $b_1 = -0.21$ означает, что при увеличении возраста дома на 1 год цена снижается в среднем на 0.21 единицы.
- Коэффициент $b_2 = -0.005$ означает, что при увеличении расстояния до метро на 1 метр цена снижается в среднем на 0.005 единиц (то есть на 5 единиц при увеличении расстояния на 1000 метров).
- Коэффициент $b_3 = 1.42$ означат, что каждый дополнительный магазин в шаговой доступности увеличивает цену в среднем на 1.42 единицы.

Для проверки качества модели выполнено предсказание на тестовой выборке. Рассчитаны следующие метрики [3]:

- MAE (средняя абсолютная ошибка)
- RMSE (среднеквадратическая ошибка)
- R^2 (коэффициент детерминации)

Код:

```
mae = sum(abs(y_test - y_pred)) / len(y_test)
```

```
rmse = (sum((y_test - y_pred)**2) / len(y_test)) ** 0.5
```

```
ss_res = sum((y_test - y_pred)**2)
```

```
ss_tot = sum((y_test - np.mean(y_train))**2)
```

```
r2 = 1 - ss_res/ss_tot
```

Результаты оценки качества (см. Таблицу 1):

Таблица 1 – результат оценки качества.

Метрики	Значение	Интерпретация
MAE	6.2	В среднем модель ошибается на 6.2 единиц
RMSE	7.68	Квадратный корень из средней квадратичной ошибки
R^2	0.6	Модель объясняет 60% дисперсии целевой переменной

MAE = 6.2 означает, что в среднем предсказанная цена отклоняется от фактической на 6.2 единиц. При средней цене в выборке 37.7 единицы относительная ошибка составляет около 16,4% ($6.2 / 37.7 \approx 0.164$). Это

приемлемый результат для задачи оценки недвижимости, учитывая сложность прогнозирования цен [3].

$RMSE = 7.68$ незначительно превышает MAE (разница около 23%), что свидетельствует о наличии небольшого количества умеренных выбросов в данных. Если бы выбросы были значительными, $RMSE$ был бы намного больше MAE [3].

$R^2 = 0.6$ означает, что построенная модель объясняет 60% дисперсии цены. Оставшиеся 40% дисперсии обусловлены факторами, не учтёнными в модели (локация, состояние здания и другие) [3, 9].

Для проверки обоснованности отбора признаков были построены три модели с разным набором признаков. Результат приведены в таблице 2.

Таблица 2 – сравнения качества с другими моделями.

Признаки, которые включены в модель	mae	rmse	R^2
$X1 + X2 + X3 + X4 + X5 + X6$	6.003	7.34	0.63
$X2 + X3 + X4$	6.2	7.68	0.6
$X3 + X4$	6.6	8.66	0.49

Как видно из таблицы 1, добавления возраста дома ($X2$) даёт наибольший прирост качества: R^2 увеличивается с 0.49 до 0.6, то есть на 0.11. Это означает, что возраст дома является важным фактором, хотя на диаграмме рассеивания его линейная связь с цена не очевидна. При совместном использовании с признаками $X3$ и $X4$ возраст дома усиливает предсказательную способность модели.

Добавление остальных признаков ($X1$, $X5$, $X6$) в модель даёт лишь незначительный прирост — R^2 увеличивается с 0.60 до 0.63 (+0.03). Это свидетельствует о том, что их вклад в модель не является критическим.

Таким образом, финальная модель с тремя признаками признана оптимальной (возраст дома, расстояния до ближайшей станции метро, количество магазинов в шаговой доступности). Она обеспечивает высокое качество прогнозирования ($R^2 = 0.6$), сохраняя при этом простоту.

ЗАКЛЮЧЕНИЕ

В ходе выполнения курсовой работы была построена и исследована модель линейной регрессии для прогнозирования стоимости недвижимости на основе набора данных Real Estate Valuation Data Set с репозитория UCI Machine Learning Repository [1].

Цель работы, сформулированная как повышение точности прогнозирования стоимости недвижимости за счёт построения и анализа модели линейной регрессии, достигнута. Построенная модель позволяет по характеристикам объекта недвижимости предсказывать его цену за единицу площади с приемлемой точностью.

В соответствии с поставленными задачами, в ходе работы были выполнены следующие этапы:

1. **Загрузка и обзор данных** – датасет содержит 414 наблюдений и 6 признаков. Пропуски отсутствуют. Целевая переменная – цена за единицу площади. Признаки включают дату сделки, возраст дома, расстояние до метро, количество магазинов, широту и долготу.
2. **Визуальный анализ данных** – построены диаграммы размаха (boxplot) и графики рассеивания для каждого признака с использованием библиотеки Plotly [4, 10]. Выявлены выбросы: минимальное значение цены 7.6, максимальное – 117.5, а также объекты с аномально большим расстоянием до метро (более 6000 метров). Визуальный анализ позволил предварительно оценить характер связи каждого признака с целевой переменной.
3. **Обработка данных** – для устранения выбросов применён процентильный метод (отсечение нижнего и верхнего 1% значений целевой переменной) [3]. Удалено 10 строк (около 2,4% данных). Объекты с расстоянием до метро более 6000 метров также были исключены. В результате очистки распределение цены стало более компактным, что положительно сказалось на устойчивости модели.
4. **Моделирование** – построена модель множественной линейной регрессии с использованием метода наименьших квадратов [5, 6]. Коэффициенты модели получены вручную через нормальное уравнение без применения сторонних библиотек машинного обучения, что подтверждает понимание математической основы метода. Данные разделены на обучающую (80%) и тестовую (20%) выборки для честной

оценки качества [9]. Для обоснования выбора признаков были построены три модели с разными наборами признаков. Результаты сравнения показали:

- модель с двумя признаками (X_3, X_4) дала $R^2 = 0.49$;
- модель с тремя признаками (X_2, X_3, X_4) дала $R^2 = 0.60$ – прирост 0.11;
- модель со всеми шестью признаками дала $R^2 = 0.63$ – прирост всего 0.03 относительно модели с тремя признаками.

Уравнение финальной модели имеет вид:

$$\hat{y} = 41.03 - 0.21x_2 - 0.005x_3 + 1.42x_4$$

Таким образом, все поставленные задачи решены, цель курсовой работы достигнута. Построенная модель интерпретируема, проста в реализации и может быть использована для приблизительной оценки стоимости объектов недвижимости в районах со схожими характеристиками.

СПИСОК ИСПОЛЬЗУЕМОЙ ЛИТЕРАТУРЫ

1. **UCI Machine Learning Repository**. Real Estate Valuation Data Set [Электронный ресурс]. – Режим доступа: <https://archive.ics.uci.edu/dataset/477/real+estate+valuation+data+set> (дата обращения: 10.06.2026)
2. **Habr**. Линейная регрессия: от теории до production [Электронный ресурс]. – Режим доступа: <https://habr.com/ru/articles/1004248/> (дата обращения: 10.06.2026)
3. **Habr**. Простыми словами про метрики в ИИ. Регрессия. MSE, RMSE, MAE, R-квадрат, MAPE [Электронный ресурс]. – Режим доступа: <https://habr.com/ru/articles/820499/> (дата обращения: 10.06.2026)
4. **Habr**. Шпаргалка по визуализации данных в Python с помощью Plotly [Электронный ресурс]. – Режим доступа: <https://habr.com/ru/articles/502958/> (дата обращения: 10.06.2026)
5. **Habr**. Как бы я рассказал про линейную регрессию (если б меня кто-то спросил) [Электронный ресурс] – Режим доступа: <https://habr.com/ru/articles/1013998/> (дата обращения: 10.06.2026)
6. **Habr**. Метод наименьших квадратов: формулы, код и применение [Электронный ресурс] – Режим доступа: <https://habr.com/ru/articles/672540/> (дата обращения: 10.06.2026)
7. **Habr**. Pandas на Python: от чтения CSV до сложной аналитики за 1 статью [Электронный ресурс] – Режим доступа: <https://habr.com/ru/articles/1005114/> (дата обращения: 10.06.2026)
8. **Habr**. NumPy: шпаргалка для начинающих [Электронный ресурс] – Режим доступа: <https://habr.com/ru/articles/768188/> (дата обращения: 10.06.2026)
9. **Мюллер А., Гвидо С.** Введение в машинное обучение с помощью Python. – М.: Вильямс, 2017. – 400 с.
10. **Документация Plotly** [Электронный ресурс]. – Режим доступа: <https://plotly.com/python/> (дата обращения: 10.06.2026)
11. **Документация NumPy** [Электронный ресурс]. – Режим доступа: <https://numpy.org/doc/stable/> (дата обращения: 10.06.2026)

12. **Документация** Pandas [Электронный ресурс]. – Режим доступа:
<https://pandas.pydata.org/docs/> (дата обращения: 10.06.2026)

ПРИЛОЖЕНИЕ

Код:

```
import numpy as np
import pandas as pd
import plotly.express as px

df = pd.read_excel("data/Real estate valuation data set.xlsx", index_col=0)

fig_bloplot_y = px.box(df, y="Y house price of unit area")
fig_bloplot_y.update_layout(width=800, height=600, font=dict(size=14))
#fig_bloplot_y.show()

lower = df["Y house price of unit area"].quantile(0.01)
upper = df["Y house price of unit area"].quantile(0.99)

df = df[(df["Y house price of unit area"] >= lower) & (df["Y house price of unit area"] <= upper)]
df = df[df["X3 distance to the nearest MRT station"] <= 6000]

fig_bloplot_y = px.box(df, y="Y house price of unit area")
fig_bloplot_y.update_layout(width=800, height=600, font=dict(size=14))
#fig_bloplot_y.show()

fig_scatter_x1 = px.scatter(
    x=df["X1 transaction date"],
    y=df["Y house price of unit area"],
    labels={"x": "Дата сделки (доли года)", "y": "Цена за единицу площади"},
    title="Рисунок 3 - Зависимость цены от даты сделки",
    opacity=0.6
)
```

```
fig_scatter_x1.update_layout(width=800, height=600, font=dict(size=14))
#fig_scatter_x1.show()
```

```
fig_scatter_x2 = px.scatter(
    x=df["X2 house age"],
    y=df["Y house price of unit area"],
    labels={"x": "Возраст дома, лет", "y": "Цена за единицу площади"},
    title="Рисунок 4 - Зависимость цены от возраста дома",
    opacity=0.6
)
```

```
fig_scatter_x2.update_layout(width=800, height=600, font=dict(size=14))
#fig_scatter_x2.show()
```

```
fig_scatter_x3 = px.scatter(
    x=df["X3 distance to the nearest MRT station"],
    y=df["Y house price of unit area"],
    labels={"x": "Расстояние до метро, м", "y": "Цена за единицу площади"},
    title="Рисунок 5 - Зависимость цены от расстояния до метро",
    opacity=0.6
)
```

```
fig_scatter_x3.update_layout(width=800, height=600, font=dict(size=14))
#fig_scatter_x3.show()
```

```
fig_scatter_x4 = px.scatter(
    x=df["X4 number of convenience stores"],
    y=df["Y house price of unit area"],
    labels={"x": "Количество магазинов", "y": "Цена за единицу площади"},
    title="Рисунок 6 - Зависимость цены от количества магазинов",
    opacity=0.6
)
```

```
fig_scatter_x4.update_layout(width=800, height=600, font=dict(size=14))
#fig_scatter_x4.show()
```

```
fig_scatter_x5 = px.scatter(
    x=df["X5 latitude"],
    y=df["Y house price of unit area"],
    labels={"x": "Широта", "y": "Цена за единицу площади"},
    title="Рисунок 7 - Зависимость цены от широты",
    opacity=0.6
)
fig_scatter_x5.update_layout(width=800, height=600, font=dict(size=14))
#fig_scatter_x5.show()
```

```
fig_scatter_x6 = px.scatter(
    x=df["X6 longitude"],
    y=df["Y house price of unit area"],
    labels={"x": "Долгота", "y": "Цена за единицу площади"},
    title="Рисунок 8 - Зависимость цены от долготы",
    opacity=0.6
)
fig_scatter_x6.update_layout(width=800, height=600, font=dict(size=14))
#fig_scatter_x6.show()
```

```
# Модель со всеми признаками
```

```
x_raw = df[["X1 transaction date", "X2 house age", "X3 distance to the nearest MRT
station", "X4 number of convenience stores", "X5 latitude", "X6 longitude"]].values
y = df["Y house price of unit area"].values
```

```
X = np.hstack([np.ones((x_raw.shape[0], 1)), x_raw])
```

```
np.random.seed(42)
```

```
indices = np.arange(len(X))
```

```
np.random.shuffle(indices)
```

```
split_idx = int(0.8*len(X))
```

```
train_indices = indices[:split_idx]
```

```
test_indices = indices[split_idx:]
```

```
X_train = X[train_indices]
```

```
X_test = X[test_indices]
```

```
y_train = y[train_indices]
```

```
y_test = y[test_indices]
```

```
coef = np.linalg.inv(X_train.T @ X_train) @ X_train.T @ y_train
```

```
b0, b1, b2, b3, b4, b5, b6 = coef
```

```
y_pred = X_test @ coef
```

```
mae = sum(abs(y_test - y_pred)) / len(y_test)
```

```
rmse = (sum((y_test - y_pred)**2) / len(y_test)) ** 0.5
```

```
ss_res = sum((y_test - y_pred)**2)
```

```
ss_tot = sum((y_test - np.mean(y_train))**2)
```

```
r2 = 1 - ss_res/ss_tot
```

```
# Модель с X3, X4
```



```
x_raw = df[["X3 distance to the nearest MRT station", "X4 number of convenience stores"]].values
```

```
y = df["Y house price of unit area"].values
```

```
X = np.hstack([np.ones((x_raw.shape[0], 1)), x_raw])
```

```
np.random.seed(42)
```

```
indices = np.arange(len(X))
```

```
np.random.shuffle(indices)
```

```
split_idx = int(0.8*len(X))
```

```
train_indices = indices[:split_idx]
```

```
test_indices = indices[split_idx:]
```

```
X_train = X[train_indices]
```

```
X_test = X[test_indices]
```

```
y_train = y[train_indices]
```

```
y_test = y[test_indices]
```

```
coef = np.linalg.inv(X_train.T @ X_train) @ X_train.T @ y_train
```

```
b0, b1, b2 = coef
```

```
y_pred = X_test @ coef
```

```
mae = sum(abs(y_test - y_pred)) / len(y_test)
```

```
rmse = (sum((y_test - y_pred)**2) / len(y_test)) ** 0.5
```

```

ss_res = sum((y_test - y_pred)**2)
ss_tot = sum((y_test - np.mean(y_train))**2)
r2 = 1 - ss_res/ss_tot

print(mae, rmse, r2)

# Модель с X2, X3, X4
x_raw = df[["X2 house age", "X3 distance to the nearest MRT station", "X4 number
of convenience stores"]].values
y = df["Y house price of unit area"].values

X = np.hstack([np.ones((x_raw.shape[0], 1)), x_raw])

np.random.seed(42)

indices = np.arange(len(X))
np.random.shuffle(indices)

split_idx = int(0.8*len(X))

train_indices = indices[:split_idx]
test_indices = indices[split_idx:]

X_train = X[train_indices]
X_test = X[test_indices]
y_train = y[train_indices]
y_test = y[test_indices]

coef = np.linalg.inv(X_train.T @ X_train) @ X_train.T @ y_train

```

```
b0, b1, b2, b3 = coef
```

```
y_pred = X_test @ coef
```

```
mae = sum(abs(y_test - y_pred)) / len(y_test)
```

```
rmse = (sum((y_test - y_pred)**2) / len(y_test)) ** 0.5
```

```
ss_res = sum((y_test - y_pred)**2)
```

```
ss_tot = sum((y_test - np.mean(y_train))**2)
```

```
r2 = 1 - ss_res/ss_tot
```